

Resumen del Trabajo Fin de Máster: Mantenimiento Predictivo Inteligente

Jose Antonio Castro

<https://github.com/Joseancc125/TFM-FAILURE-PREDICTION.git>

Mi objetivo principal ha sido desarrollar un sistema inteligente que analice los datos de los sensores de maquinaria industrial para predecir averías antes de que ocurran, traduciendo datos técnicos complejos a información útil para la toma de decisiones.

1. Objetivo General

El propósito de este proyecto ha sido transformar las lecturas de los sensores en alertas preventivas. Nos propusimos analizar el comportamiento de las máquinas, detectar anomalías, comparar algoritmos de inteligencia artificial y mostrarlo todo en un panel visual e interactivo fácil de entender.

2. Fases del Proyecto: Objetivos vs. Resultados Obtenidos

Fase 1: Comprensión del problema y análisis exploratorio

- **Objetivo:** Entender el conjunto de datos, ver cómo se relacionaban los sensores y comprobar si había desbalance (más casos normales que fallos).
- **Resultado:** Trabajamos con una base de 944 registros operativos. Afortunadamente, los datos estaban muy equilibrados (58.37 % de funcionamiento normal y 41.63 % de fallos), lo que nos permitió entrenar al modelo sin sesgos por falta de ejemplos de averías.

Fase 2: Calidad y preparación de los datos

- **Objetivo:** Limpiar la base de datos, buscar valores nulos, duplicados y preparar todo para los algoritmos.
- **Resultado:** Confirmamos que la base de datos era de altísima calidad. No había valores nulos y solo tuvimos que eliminar un registro duplicado. Separamos los datos para entrenar y evaluar el modelo asegurando que la proporción de fallos se mantenía estable.

Fase 3: Ingeniería de características (Creación de nuevos indicadores)

- **Objetivo:** Inventar nuevas variables a partir de los sensores existentes que tuvieran más sentido para el equipo de mantenimiento.
- **Resultado:** Creamos 11 variables nuevas. En lugar de mirar la presión o la temperatura por separado, creamos indicadores como el Índice de Salud de la Máquina o la Puntuación de Riesgo. Esto fue clave, ya que “hablan” el mismo idioma que los operarios y mejoran muchísimo la predicción.

Fase 4: Detección de anomalías

- **Objetivo:** Implementar técnicas que detecten comportamientos “raros” o atípicos de la máquina.
- **Resultado:** Probamos los sistemas Isolation Forest y Local Outlier Factor (LOF). Aunque detectar una anomalía no significa siempre que la máquina vaya a romperse, sí nos sirve como una excelente primera capa de alerta para vigilar el equipo de cerca.

Fase 5: Predicción de fallos

Comparamos tres modelos avanzados de Machine Learning para predecir si una máquina estaba a punto de fallar. Aquí están los resultados:

Modelo Evaluado	Rendimiento y Conclusión
Random Forest	El Ganador. Excelente precisión para distinguir estados de riesgo frente a estados normales.
XGBoost	Resultados muy competitivos, pero ligeramente por debajo del ganador en la detección de los fallos más críticos.
LightGBM	Rápido y eficiente, pero Random Forest demostró ser más robusto para nuestro problema concreto.

Fase 6: Interpretación de resultados

- **Objetivo:** Entender por qué el modelo dice que una máquina va a fallar (evitar la “caja negra”).
- **Resultado:** Las variables que se crearon en la Fase 3 (como el riesgo global y la salud de la máquina) resultaron ser las más importantes para el modelo. Esto confirma que el algoritmo realmente está entendiendo el desgaste operativo del equipo.

Fase 7: Visualización y Dashboard

- **Objetivo:** Crear una pantalla interactiva y visual para que cualquier persona pueda consultar el estado de la planta.
- **Resultado:** Desarrollé un Dashboard interactivo usando Streamlit. Está diseñado para ir al grano: muestra el riesgo estimado actual, si hay alertas anómalas, y la salud general de las máquinas, dejando los datos técnicos complejos en un segundo plano.

3. Conclusión y Futuro

El sistema cumple su objetivo con creces: hemos pasado de tener una “sopa de datos” de sensores a contar con una herramienta capaz de anticipar problemas con alta precisión. Como próximos pasos, propongo integrar más datos históricos, añadir alertas automáticas y desplegar el sistema para que funcione en tiempo real en la fábrica.